

第十三講：因果森林 講稿

第十三講：因果機器學習（三）：因果森林

講稿（台灣中文）

封面頁

各位同學好，今天我們進入因果機器學習的第三講，主題是**因果森林（Causal Forest）**。

前面幾講我們介紹了 LASSO 等預測型機器學習工具，以及雙重差分搭配機器學習的做法。今天我們要討論一個不同的問題：我們不只想知道政策的平均效果，還想知道效果是不是因人而異——有些人效果大、有些人效果小——以及這種差異和哪些個人特徵有關。

【第一部分：主要概念】

今天的目標

這張投影片列出今天的五個學習目標，讓我一一說明。

第一個目標：了解因果森林在解決什麼問題。 簡單來說，它在解決「誰從政策中受益」這個問題，也就是處理效果的異質性。

第二個目標：學習決策樹和隨機森林的基本直觀。 因果森林建立在隨機森林的技術基礎上，所以我們要先理解這些工具的核心邏輯，才能真正理解因果森林在做什麼。我們不會把所有數學細節都推導出來，重點是掌握直觀。

第三個目標：了解因果解釋所需的假設。 機器學習很靈活，但靈活不代表就能做因果推論。我們需要和之前一樣的識別假設，這一點非常重要。

第四個目標：讀懂主要輸出結果。 包括 ATE、CATE 分布、BLP（最佳線性投影）以及變數重要性這幾個報表。

第五個目標：看懂 R 的 grf 套件如何操作。 我們會用 LaLonde 就業訓練資料走一遍完整流程。

一句話摘要

先給大家一個最簡單的定義：

因果森林估計處理效果如何隨可觀測特徵 X 變化，方法是平均許多棵誠實的因果樹。

圖中的三個方塊表示流程：我們把資料 (Y, D, X) 輸入進去，長出許多棵誠實的因果樹，然後得到每個人的 CATE 估計值 $\hat{\tau}(x)$ 。

有兩點很重要，底下特別強調：- 因果森林**不只**是一個預測工具。- 它的核心用途是幫我們了解「誰受益更多」。

這個區別很關鍵。一般的機器學習是預測 Y ；因果森林是估計 $\tau(x) = E[Y^1 - Y^0 \mid X = x]$ ，這是一個因果量。

和前面幾講的連結

我們來看一下這一講如何接續之前的內容。

在大多數之前的講次中，我們估計的是一個**平均**因果參數，就是 ATE：

$$\alpha_{\text{ATE}} = E[Y_i^1 - Y_i^0]$$

這是對全樣本的平均效果，一個數字。

有時我們更關心受處理者的效果，也就是 ATT：

$$\alpha_{\text{ATT}} = E[Y_i^1 - Y_i^0 \mid D_i = 1]$$

今天這一講問的問題更細：

$$\alpha_{\text{CATE}}(x) = E[Y_i^1 - Y_i^0 \mid X_i = x]$$

也就是說，對於特徵為 x 的那一群人，處理效果是多少？這是一個**函數**，而不是一個單一數字。

運行範例：就業訓練

今天整堂課我們會用一個勞動經濟學的例子來說明。

設想政府提供一個就業訓練計劃：- **結果** Y_i ：參加計劃後的薪資所得 - **處理** D_i ：工作者 i 是否接受訓練 - **共變數** X_i ：年齡、教育年數、種族、婚姻狀況、過去所得

核心政策問題是：訓練計劃對所有人的效果都一樣嗎？還是對某些人特別有效？

這個問題在實務上非常重要。如果預算有限，我們想把訓練資源集中給效果最大的群體。

從 ATE 到 CATE

左邊是 ATE，右邊是 CATE，我們來比較一下。

ATE 是全樣本的平均效果，只有一個數字，雖然有用，但它把效果的異質性給平均掉了。

CATE 是條件平均處理效果，對特徵為 x 的人，處理效果是多少。它對目標資源分配和機制研究都很有用。

在因果森林的文獻中，CATE 通常寫成 $\tau(x)$ ，我在這堂課也會用這個符號。

ATE 和 ATT 與 CATE 的關係

這邊有一個很重要的概念：ATE 和 ATT 其實都是 CATE 的平均值。

一旦我們知道了 CATE 函數 $\tau(x)$ ，就可以對它取平均：

$$\alpha_{\text{ATE}} = E[\tau(X_i)]$$

$$\alpha_{\text{ATT}} = E[\tau(X_i) \mid D_i = 1]$$

所以因果森林並不取代 ATE 或 ATT 的估計。它估計的是一個更豐富的對象，我們再從這個對象推導出熟悉的政策摘要統計量。

這個順序很重要：先估計 CATE，再平均得 ATE 或 ATT。

為什麼異質性很重要

來看這張表。同樣是接受訓練：

工作者類型	未訓練薪資	訓練後薪資	效果
年輕、低教育	\$8,000	\$11,000	\$3,000
年長、高經驗	\$18,000	\$18,500	\$500
長期失業者	\$2,000	\$6,000	\$4,000

三種人的效果差距非常大。如果只看平均效果，我們可能說「訓練計劃有效」，但其實效果高度集中在某幾類人身上。

政策含義：如果政府知道哪類人效果最大，就可以做更精準的目標設計（targeting），用有限的預算創造最大效益。這就是 CATE 的價值所在。

因果推論的根本問題

在進入技術之前，我們要先承認一個根本問題——這和我們第一講就強調的一樣。

每個人有兩個潛在結果：

$$Y_i^1 \quad (\text{如果接受處理}), \quad Y_i^0 \quad (\text{如果未接受處理})$$

個體處理效果是：

$$\tau_i = Y_i^1 - Y_i^0$$

但我們只觀察到其中一個：

$$Y_i = D_i Y_i^1 + (1 - D_i) Y_i^0$$

所以因果森林沒有魔法，它不能直接觀察個體效果。它估計的是「特徵相似的人」的平均效果。這一點務必清楚。

識別假設

要對 CATE 做因果解釋，我們需要和之前一樣的**條件獨立假設**：

$$(Y_i^1, Y_i^0) \perp D_i \mid X_i$$

意思是：在控制可觀測共變數 X_i 之後，接受處理與否對潛在結果而言如同隨機分配。

幾個重點：- 在隨機實驗中，這個假設自動成立。- 在觀察性資料中，這個假設需要豐富的共變數，而且研究設計要很謹慎。- **因果森林是一個估計工具，不是識別策略的替代品**。識別問題還是要靠研究設計來解決。

這是很多同學容易誤解的地方：機器學習方法越精巧，不代表識別假設就自動得到滿足。

CATE 的識別

在條件獨立假設成立的前提下，CATE 可以寫成：

$$\tau(x) = E[Y_i | X_i = x, D_i = 1] - E[Y_i | X_i = x, D_i = 0]$$

這個式子和我們熟悉的「處理組減去對照組」是一樣的，只是現在是條件在 $X_i = x$ 的比較。

困難之處在於： X_i 可能有很多個變數，如果要精確地把 $X_i = x$ 的人找出來，每個格子裡的人數會非常少，估計就會很不穩定。

因果森林的作用就是用決策樹自動找到有用的局部比較，不需要我們事先指定格子。

【第二部分：決策樹與隨機森林】

為什麼需要彈性的方法

一個直觀的想法是在迴歸中加入交叉項：

$$Y_i = \delta + \alpha D_i + X_i \beta + (D_i \times X_i) \gamma + \epsilon_i$$

這個方法有用，但有限制：它假設處理效果是 X_i 的線性函數。

現實中，處理效果可能取決於非線性模式，例如：- 年輕「而且」教育程度低才有大效果（交叉作用）- 只有過去所得低於某個門檻的人才受益（閾值效果）

這些模式很難事先猜到應該加哪些交叉項。因果森林能更彈性地搜尋這些模式。

什麼是決策樹

決策樹是一種利用共變數做分組的工具。它的邏輯非常簡單：

不斷問是非題（例如「年齡是否小於25？」），每問一個問題就把樣本分成兩組，最終形成一些小的分組，稱為**葉節點 (leaf)** 或**終端節點 (terminal node)**。

在每個葉節點裡，用一個簡單的估計：

$$\hat{m}(\ell) = \frac{1}{N_\ell} \sum_{i: X_i \in \ell} Y_i$$

就是葉節點裡所有人的平均結果。

所以決策樹的本質是：**用資料自動找出有意義的分組**，而不是事先指定分組。

決策樹：預測版本

圖中是一棵預測樹的例子。

第一個問題：年齡是否小於25？ - 如果是，再問：教育年數是否小於12？ - 如果是：預測薪資 \$9,000 - 如果否：預測薪資 \$12,000 - 如果否，再問：過去所得是否小於 \$5,000？ - 如果是：預測薪資 \$10,500 - 如果否：預測薪資 \$18,000

每個葉節點給一個預測值，就是那個葉節點裡所有人的平均薪資。

這棵樹很好解讀，但有一個大問題：**單一決策樹非常不穩定**。換一批資料，第一個分割可能就不同了，後面的結構也會跟著全變。

決策樹：共變數空間的分割

這張圖展示的是決策樹的幾何意義。

以年齡和教育為兩個軸，決策樹把這個空間切割成幾個矩形區域（葉節點）。

落在同一個葉節點的人，就用同一個預測值。樹越深、切割越多，每個區域越小，預測越靈活，但也越容易過度配適（overfitting）。

預測樹如何選擇分割

預測樹選擇分割的標準是：找到讓「預測誤差最小」的分割點。

對每個候選分割，計算兩個子群的殘差平方和：

$$\sum_{i \in R_1} (Y_i - \bar{Y}_{R_1})^2 + \sum_{i \in R_2} (Y_i - \bar{Y}_{R_2})^2$$

選最小的那個分割。

直觀上就是：把「結果相似的人」放進同一個葉節點。

為什麼單一決策樹不夠

單一決策樹雖然好解讀，但**變異數非常高**。

- 資料小幅變動，第一個分割就可能改變
- 第一個分割改變，後面所有分割都連帶改變
- 預測結果因此很不穩定

這個問題在因果推論中更嚴重，因為處理效果的估計本來就比平均結果更難、訊噪比更低。

核心問題：**一棵樹太依賴某一個特定樣本**。

隨機森林：平均許多棵樹來穩定估計

隨機森林的解決方案很直觀：長很多棵樹，然後平均。

每棵樹在不同的隨機子樣本上生長，每棵樹的估計都有雜訊，但平均之後會更穩定：

$$\hat{m}(x) = \frac{1}{B} \sum_{b=1}^B \hat{m}_b(x)$$

預測型隨機森林估計的是：

$$m(x) = E[Y_i \mid X_i = x]$$

因果森林保留了森林的技術架構，但把目標從「預測 Y 」換成「估計處理效果 $\tau(x)$ 」。

隨機森林：兩個產生多樣性的機制

隨機森林讓每棵樹都不一樣，靠的是兩個機制：

第一：子取樣 (subsampling) - 每棵樹只看到一個隨機的子樣本 - 不同棵樹學到略微不同的模式

第二：隨機分割變數 - 在每個節點，只從隨機選出的部分共變數中挑選分割變數 - 這樣可以避免所有樹都長得太像

為什麼這樣做有效？因為**平均獨立的、有用但不相同的估計**，比平均高度相關的估計效果好得多。想像10個獨立觀點的平均，和10個幾乎相同觀點的平均，哪個更有資訊？

橋接到因果森林

這張表是關鍵的橋接點：

步驟	預測森林	因果森林
樹怎麼長葉節點	結果相似的人	處理效果相似的人
葉節點估計值	$\bar{Y}_\ell$	$\bar{Y}_\ell^1 - \bar{Y}_\ell^0$
森林平均	$\hat{m}(x)$	$\hat{\tau}(x)$
核心問題	結果可能是多少？	誰受益更多？

關鍵轉換：因果森林保留樹和森林的機制，但把分割的目標從「預測 Y 」改成「找到處理效果不同的群體」。

【第三部分：因果樹】

從預測樹到因果樹

這張表再次整理預測樹和因果樹的差別。

最核心的差別是**分割的邏輯**：- 預測樹：找「結果 Y 水準不同」的切割點 - 因果樹：找「處理效果 D 不同」的切割點

葉節點的估計也不同：- 預測樹：那個葉的平均 Y - 因果樹：處理組減去對照組的差，也就是 $\bar{Y}_\ell^1 - \bar{Y}_\ell^0$

對應的問題分別是：「誰的薪資高？」vs. 「誰從訓練中獲益更多？」

因果樹：葉節點的直觀

來看一個具體例子。

葉節點	處理組平均	對照組平均	估計效果
年輕、低教育	\$11,000	\$8,000	\$3,000
年長、高經驗	\$18,500	\$18,000	\$500

在每個葉節點內，直接比較處理組和對照組。葉節點的估計就是一個局部平均處理效果：

$$\hat{\tau}(\ell) = \bar{Y}_{\ell}^1 - \bar{Y}_{\ell}^0$$

一個新的工作者，根據他的特徵 $\mathbf{X}_i$ 落在哪個葉節點，就得到那個葉節點的效果估計。

因果樹：如何找分割點

因果樹找分割點的步驟如下：

1. 對每個變數 X^j 和候選分割點 s ，建立兩個區域：

$$R_1(j, s) = \{i : X_i^j < s\}, \quad R_2(j, s) = \{i : X_i^j \geq s\}$$

2. 在每個區域估計處理效果：

$$\hat{\tau}(R) = \bar{Y}_R^1 - \bar{Y}_R^0$$

3. 選擇讓兩個區域的處理效果差距最大的分割：

$$\Delta(j, s) = |\hat{\tau}(R_1) - \hat{\tau}(R_2)|$$

因果樹在找「效果不同的群體」，而不是「結果水準不同的群體」。這是和預測樹最根本的區別。

因果樹：一個小型分割範例

來看一個具體的數字範例。

候選分割	$\hat{\tau}(R_1)$	$\hat{\tau}(R_2)$	Δ
年齡 < 30	\$3,000	\$600	\$2,400
教育 < 12	\$2,100	\$1,400	\$700
過去所得 < 5,000	\$2,600	\$1,000	\$1,600

在這個例子中，樹會先用年齡來分割，因為年齡分割造成的效果差距最大（\$2,400）。

注意：這不是說年齡「永遠」是最重要的，只是在這個資料中，年齡分割最能把效果大的人和效果小的人區分開來。

主要問題：雙重使用資料 (Double Dipping)

因果樹有一個嚴重的問題，叫做「雙重使用資料」(double dipping)。

如果用同一批資料：1. 決定在哪裡切割 (tree structure selection) 2. 估計葉節點的處理效果

那麼樹可以對隨機雜訊過度配適。一個切割看起來很好，可能只是因為它在這個樣本中運氣好，而不是真的有意義。

結果是：葉節點的處理效果估計值在量值上會偏高，因為樹已經「看過」這些資料才選出這個切割。

這就像考試作弊：如果你看過考題再寫答案，成績當然好，但反映的不是真實能力。

誠實估計 (Honest Estimation)

解決方法是「誠實估計」(honest estimation)。

每個子樣本被分成兩個部分：- **分割樣本**：用來決定樹的結構 (在哪裡切割) - **估計樣本**：用來估計最終葉節點的處理效果

這兩個樣本完全獨立。分割結構是根據一批資料決定的，但葉節點的效果估計用的是另一批沒有參與分割決策的資料。

效果：- 減少過度配適 - 支持有效的統計推論 (valid inference)

這是因果樹和一般決策樹最關鍵的技術差別，也是讓因果森林具備統計有效性的基礎。

【第四部分：因果森林】

因果森林算法

完整的因果森林算法如下：

1. 抽一個隨機子樣本
2. 把子樣本分成兩部分：一個選分割，一個估計效果
3. 長一棵誠實的因果樹
4. 重複很多次，例如 $B = 2,000$ 棵樹
5. 對每個觀察值，平均所有樹的估計：

$$\hat{\tau}(x_i) = \frac{1}{B} \sum_{b=1}^B \hat{\tau}_b(x_i)$$

就這樣。每棵樹都是誠實的，每棵樹的雜訊都略有不同，平均之後估計更穩定。

因果森林作為自適應加權

另一個理解因果森林的角度是把它看成**自適應加權**的局部比較。

對目標工作者 x ：- 森林找出其他和 x 特徵相似的人（常常落在同一個葉節點）- 這些人在估計 $\tau(x)$ 時得到較大的權重

概念上：

$$\hat{\tau}(x) \approx \sum_{i:D_i=1} a_i(x) Y_i - \sum_{i:D_i=0} a_i(x) Y_i$$

其中 $a_i(x)$ 是根據「觀察值 i 和 x 的相似程度」決定的權重。

所以因果森林有點像是**彈性的配對方法**：它自動找到和你最像的處理組和對照組，用他們來估計你的效果。而且這個配對標準是從資料中自動學習的，不需要事先指定。

為什麼平均有效

單棵因果樹的估計可以這樣想：

$$\hat{\tau}_b(x) = \tau(x) + \varepsilon_b$$

ε_b 是第 b 棵樹的估計誤差。

當我們平均 B 棵樹：

$$\frac{1}{B} \sum_{b=1}^B \hat{\tau}_b(x) = \tau(x) + \frac{1}{B} \sum_{b=1}^B \varepsilon_b$$

如果每棵樹的誤差部分互相抵消（因為每棵樹用的是不同的隨機子樣本），平均之後的估計就會越來越接近真實值。這就是**偏差-變異數取捨**的一個應用：每棵樹偏差小但變異大，平均之後變異大幅降低。

隨機森林 vs. 因果森林

這是一張很重要的比較表：

	隨機森林	因果森林
主要目標	預測結果	估計處理效果
輸入	(Y, X)	(Y, D, X)
估計對象	$\hat{m}(x)$	$\hat{\tau}(x)$
分割標準	降低預測誤差	找處理效果異質性
葉節點值	平均結果	處理-對照差距
誠實估計	通常沒有	有

特別要強調這一點：因果森林不是把處理變數 D 當作一個額外的預測變數加進隨機森林而已。這兩個是完全不同的東西：隨機森林在預測，因果森林在估計因果效果。

統計性質：需要知道什麼

對這門課的程度，技術性質的部分不需要記公式，但要知道幾個關鍵點：

- 誠實因果森林在理論上既可以估計 CATE，也支持統計推論（confidence intervals）。

- 在一些正則條件下： $\hat{\tau}(x) \xrightarrow{p} \tau(x)$ ，也就是樣本越大，估計越準。
- grf 套件對 ATE 和相關匯總統計量會報告標準誤。

對教學而言，核心直觀是：- **誠實性**控制了因為自適應分割造成的偏差 - **平均很多棵樹**降低了變異數 - 但**因果解釋**仍然必須依靠研究設計（識別策略），機器學習無法自動提供

$\hat{\tau}(x_i)$ 是什麼意思

這個問題很重要，我想特別說清楚。

$\hat{\tau}(x_i)$ **不是**工作者 i 真正的個體處理效果。

它估計的是「和工作者 i 特徵相似的人」的平均處理效果。相似程度由森林從共變數 X 中學習得到。

舉例：如果 $\hat{\tau}(x_i) = 2,000$ ，意思是：和工作者 i 特徵相似的那群人，估計從訓練中平均獲益約 \$2,000 元的薪資增加。

所以報告時，應該說「具有類似特徵的工作者」而不是「這個人」。

因果森林給我們什麼

因果森林的輸出包含以下幾項：

1. **ATE**（平均處理效果）：對目標樣本的平均效果估計值
2. **ATT**（受處理者平均處理效果）：對處理組的平均效果
3. 個別的 **CATE** 估計值：每個觀察值一個 $\hat{\tau}(x_i)$
4. **CATE** 分布：效果是集成的還是非常分散？
5. **最佳線性投影**（BLP）：哪些共變數和較大的效果有關？
6. **變數重要性**：哪些變數常常被用來分割樹？

接下來我會一一說明最後幾項。

如何解讀 CATE 分布

圖中是 CATE 分布的直方圖，紅色虛線是 ATE。

解讀方式：- **分布很寬**：表示處理效果在不同人之間差異很大（高異質性）- **分布很窄**：表示大多數人的處理效果類似，不太有異質性 - **平均值（ATE）可能隱藏了「贏家」和「無反應者」**

例如，如果 $ATE = \$1,500$ ，但分布很寬，意味著有些人效果 $\$4,000$ ，有些人效果幾乎是 $\$0$ ，而這兩群人的需求和政策設計可能完全不同。

BLP：異質性的簡單摘要

CATE 估計值一個一個看很難摘要。**最佳線性投影（BLP）** 提供了一個簡便的整理方式：

用線性回歸把 CATE 估計值對共變數回歸：

$$\hat{\tau}(x_i) = \beta_0 + \beta_1 \text{age}_i + \beta_2 \text{educ}_i + \beta_3 \text{re74}_i + \cdots + \varepsilon_i$$

解讀範例：- $\hat{\beta}_1 < 0$ ：年齡較大的工作者，估計效果較小 - $\hat{\beta}_3 < 0$ ：過去所得較高的工作者，估計效果較小

重要提醒：BLP 是描述性的，它總結了森林估計出的異質性，本身不能做因果解釋。

變數重要性

變數重要性衡量「哪些變數常常被森林用來分割」。

重要性高 = 這個變數對找出處理效果不同的群體很有用。它能偵測非線性關係和交叉作用。

但注意：變數重要性不告訴你方向（正負），也就是說，一個重要性高的變數，可能是效果在高值時大，也可能在低值時大。

比較 BLP 和變數重要性的用途：- BLP：給方向和標準誤，有助於解釋哪類人效果大/小 - 變數重要性：告訴你哪些變數對分類有用，但不說方向

兩者搭配使用，才能對異質性有完整的理解。

實務警告

最後，因果森林在使用上有幾個重要的注意事項：

1. 沒有可信的識別策略，CATE 就沒有因果解釋。這是最重要的一點。

2. 不要過度解讀單一個體的估計值，要以「相似群體的平均」來思考。
3. 檢查重疊 (overlap)： X 的每個區域都要有處理組和對照組，否則效果估計沒有意義。
4. 用因果森林探索和目標設計，然後用簡單的摘要統計謹慎報告。不要報告太多細節，選幾個有意義的異質性發現即可。
5. 在小樣本中，異質性估計可能很不精確，要謹慎。

【第五部分：R 實作範例：就業訓練計劃】

LaLonde 就業訓練資料

我們用 LaLonde (1986) 的就業訓練資料做實作範例。這個資料集在勞動經濟學中非常經典。

- 處理 D_i ：是否參與訓練計劃
- 結果 Y_i ：1978 年的薪資所得
- 共變數 X_i ：年齡、教育年數、種族（黑人、西班牙裔）、婚姻狀況、無學位、1974 和 1975 年的過去所得

核心問題：哪類工作者從訓練中獲益最多？

R 的工作流程分為八個步驟：1. 安裝套件和載入資料 2. 準備 Y_i 、 D_i 、 X_i 3. 估計因果森林 4. 計算 ATE/ATT 5. 取得個別 CATE 估計值 6. 畫 CATE 分布圖 7. 摘要異質性（BLP 和變數重要性） 8. 匯出結果

步驟 1：安裝套件和載入資料

```
install.packages(c("grf", "Matching", "ggplot2"))
```

```
library(grf)
```

```
library(Matching)
```

```
library(ggplot2)
```

```
data(lalonde)
```

```
summary(lalonde)
```

三個套件的用途： - **grf**：廣義隨機森林，這是我們主要使用的套件， `causal_forest()` 在這裡 - **Matching**：包含 LaLonde 資料集 - **ggplot2**：視覺化

步驟 2：資料準備

```
Y <- lalonde$re78
D <- lalonde$treat
X <- lalonde[, c("age", "educ", "black", "hisp",
                "married", "nodegree", "re74", "re75")]
X <- as.matrix(X)
```

- Y ：觀察到的結果 Y_i (1978 年薪資)
- D ：處理指標 D_i (是否接受訓練)
- X ：前置共變數矩陣，注意所有變數都要是處理前測量的

X 要轉成矩陣格式，因為 `causal_forest()` 要求矩陣輸入。

步驟 3：估計因果森林

```
set.seed(2026)

cf <- causal_forest(
  X = X,
  Y = Y,
  W = D,
  num.trees = 2000
)
```

幾個說明： - $W = D$ ：grf 套件用 W 代表處理變數，但我們課程符號用 D_i ，意思一樣 - `num.trees = 2000`：樹的數量，越多通常估計越穩定，但計算時間也越長 - 套件內部自動處理誠實性和森林平均，我們不用手動設定

步驟 4：估計 ATE 和 ATT

```
ate <- average_treatment_effect(cf, target.sample = "all")
att <- average_treatment_effect(cf, target.sample = "treated")
```

```
ate
```

```
att
```

輸出的是估計值和標準誤。

- `target.sample = "all"` 估計 α_{ATE}
- `target.sample = "treated"` 估計 α_{ATT}

這樣就把新方法和我們之前學的 ATE、ATT 估計連結起來了。在 LaLonde 資料中，因果識別的基礎是隨機實驗（RCT），所以條件獨立假設自動成立。

步驟 5：取得個別 CATE 估計值

```
tau_hat <- predict(cf)$predictions
```

```
summary(tau_hat)
```

- `tau_hat` 包含每個觀察值的 CATE 估計值，一共 N 個
- 解讀： $\hat{\tau}(x_i)$ 是和工作者 i 特徵相似的人的估計訓練效果
- 用 `summary()` 看效果是否分散，或者大家差不多

步驟 6：畫 CATE 分布圖

```
cate_df <- data.frame(tau_hat = tau_hat)
```

```
ggplot(cate_df, aes(x = tau_hat)) +
  geom_histogram(bins = 30, fill = "steelblue",
                color = "white") +
  geom_vline(xintercept = mean(tau_hat),
             color = "red", linetype = "dashed") +
```

```
labs(x = "Estimated treatment effect",
     y = "Count")
```

- 紅色虛線是 CATE 估計值的平均，近似於 ATE
- 分布的寬度代表異質性的程度：分布越寬，代表不同人的效果差異越大
- 如果分布很集中在一個點，說明大家效果差不多

步驟 7：摘要異質性 (BLP 和變數重要性)

最佳線性投影

```
blp <- best_linear_projection(cf, X)
```

```
blp
```

變數重要性

```
vi <- variable_importance(cf)
```

```
names(vi) <- colnames(X)
```

```
sort(vi, decreasing = TRUE)
```

BLP 解讀： - 正係數：該共變數較高的工作者，估計效果較大 - 負係數：該共變數較高的工作者，估計效果較小 - 有標準誤，可以看哪些係數顯著

變數重要性解讀： - 分數越高，表示這個變數越常被用來分割 - 排序後可以知道哪些特徵最有助於區分高效果和低效果群體

注意：兩者都是描述性摘要，不能直接做因果解釋。

步驟 8：匯出結果給 Stata 後續分析

```
results <- data.frame(
  id      = 1:nrow(X),
  tau_hat = tau_hat,
  age     = lalonde$age,
  educ    = lalonde$educ,
  D       = lalonde$treat
)
```

```
write.csv(results, "cate_results.csv",
          row.names = FALSE)
```

這樣可以把 R 估計的 CATE 值匯出為 CSV，然後在 Stata 或 R 裡做進一步的描述性分析、製表或繪圖。

實務上的分工：在 R 估計因果森林，匯出 CATE，在習慣的環境中做摘要分析。

【第六部分：勞動經濟學應用與總結】

勞動經濟學的應用場景

因果森林在勞動經濟學中有很廣泛的應用潛力：

- **主動勞動市場計劃**：求職輔助對哪類工作者效果最好？
- **青年就業計劃**：哪類年輕人受益最多？
- **教育政策**：受教育的回報是否因家庭背景或地區勞動市場條件而異？
- **最低工資**：最低工資的就業效果是否因工作者技能、企業規模或地區而不同？
- **育嬰假政策**：效果是否因之前的薪資或職業類別而異？

這些問題的共同點是：我們不只想知道平均效果，更想知道哪類人受益最多，以便設計更精準的政策目標。

學生應該記住的事

讓我來總結這堂課的核心重點：

1. 前幾講聚焦在 α_{ATE} 和 α_{ATT} ，一個平均數。
2. CATE 問的是效果如何隨 X_i 變化： $\tau(x) = E[Y_i^1 - Y_i^0 \mid X_i = x]$
3. 決策樹建立資料驅動的分組；隨機森林通過平均很多棵樹來穩定估計。
4. 因果樹把目標從「預測結果」改成「找處理效果的異質性」，分割標準完全不同。
5. 誠實估計把分割選擇和效果估計分開，避免雙重使用資料造成的偏差。
6. 因果森林平均很多棵誠實的因果樹，穩定 $\hat{\tau}(x)$ 的估計。

使用因果森林的檢查清單

在論文或研究計劃中用到因果森林時，要確認以下幾點：

1. 定義清楚 結果 Y_i 、處理 D_i 和前置共變數 X_i
2. 說明識別假設：條件獨立假設如何在你的研究設計中成立？是 RCT 嗎？還是觀察性資料搭配豐富的共變數？
3. 檢查重疊： X_i 的相關範圍內，處理組和對照組都要有足夠的樣本
4. 估計森林，報告 $\hat{\alpha}_{ATE}$ 或 $\hat{\alpha}_{ATT}$
5. 用 CATE 分布、BLP 和變數重要性描述異質性，並謹慎解讀

【推薦文獻】

推薦資源

想深入了解因果森林的同學，推薦以下幾篇文獻：

1. **Wager and Athey (2018)**：「Estimation and Inference of Heterogeneous Treatment Effects using Random Forests」——因果森林的核心技術論文，建立了誠實估計的理論基礎
2. **Athey, Tibshirani, and Wager (2019)**：「Generalized Random Forests」——廣義隨機森林的完整理論框架，`grf` 套件就是基於這篇
3. **grf 文件**：<https://grf-labs.github.io/grf/>——套件的完整說明和範例，很實用
4. **Athey and Imbens (2019)**：「Machine Learning Methods That Economists Should Know About」——一篇很好的綜述，從經濟學家的角度介紹機器學習方法

最終結語

讓我用這張投影片的話作為結語：

因果森林幫助我們從

「政策平均而言是否有效？」

進步到

「政策對哪些人效果最好？」

但要記住：

森林估計的是異質性。因果可信度仍然來自研究設計。

這兩句話是這整堂課最重要的帶走訊息。機器學習讓我們更靈活地描述效果的異質性，但它不能取代識別策略。好的因果森林研究，必須同時有好的研究設計和靈活的估計方法。

好，今天就上到這裡，謝謝大家。

講稿作者：基於 *L13_CausalForest_labor_v4.tex* 投影片撰寫

日期：2026-05-12